Predicción del consumo diario de insumos para la reposición de inventario

Proyecto Capstone · Sistema integrado con Machine Learning

Nida Hugo Loza Guzmán · Octubre de 2026

1. Problema y objetivo

En una cafetería los insumos (leche, café en grano, harina, queso, etc.) se reponen casi siempre a ojo. Cuando se compra poco hay faltantes y se dejan de vender productos; cuando se compra de más, los perecibles se vencen. El kardex del sistema de gestión ya registra cada salida de insumo, pero esa información no se usa para anticipar la compra.

El objetivo del proyecto es predecir el consumo diario de cada insumo y, con ese pronóstico, decir cuántos días alcanza el stock y cuánto conviene reponer. La unidad de observación es un insumo en una fecha y la variable a predecir es la cantidad consumida ese día (salidas del kardex).

Se revisó la coherencia de lo registrado en el Excel de proyectos y se mantuvo: la línea base (mismo día de la semana anterior) es justamente el denominador natural de la MASE con periodo 7, así que una MASE menor a 1 se lee directamente como “mejor que la línea base”. Se hicieron dos ajustes con justificación técnica: (a) un solo modelo LightGBM global para los 14 insumos, con las cantidades normalizadas por la media de entrenamiento de cada insumo, porque por separado varios insumos tienen pocos datos; y (b) el consumo se toma neto de devoluciones de venta.

2. Dataset y preparación

Origen. Datos reales del sistema de gestión de una cafetería de Tarija (PostgreSQL 16), obtenidos de un respaldo completo de la base de datos. El periodo va del 1 de octubre de 2021 al 3 de octubre de 2026. El respaldo tiene 374 404 movimientos de kardex sobre 19 543 existencias (envases o unidades abiertas de un lote).

Privacidad. El respaldo incluye clientes, personas, usuarios y ventas. El script de extracción solo lee las tablas de productos, unidades, lotes, existencias y movimientos, y no exporta identificadores de usuario. El respaldo no se sube al repositorio; se comparte únicamente el dataset agregado por día.

Preparación. (1) Cada movimiento se asigna a su insumo base: las presentaciones de compra (por ejemplo “Harina bolsa 1 kg”) se suman a su insumo padre (“Harina”, en gramos). (2) Se toman los 14 insumos de tipo Insumo. (3) Consumo del día = consumo por producción + consumo por venta – devoluciones. Las mermas y vencimientos se guardan aparte y no se cuentan como consumo. (4) Se completa el calendario: un día sin movimientos es consumo cero (en feriados como Navidad o Carnaval la cafetería no abre). (5) El stock de cierre se reconstruye acumulando entradas (aperturas, ajustes positivos, devoluciones) menos salidas.

Dataset final	Valor
Filas (insumo × día)	25 606
Insumos	14 (g, ml o unidades)
Días	1 829 (01/10/2021 – 03/10/2026)
Variables de origen	date, item, unit, consumption, opened, waste, stock_close
Días con consumo cero	2 % (leche, café) a 50 % (harina, huevo, uso por lotes)

Variables del modelo. Para predecir el día t solo se usa información disponible al cierre de t–1: rezagos del consumo (1, 2, 3, 7, 14, 21 y 28 días), medias móviles de 7 y 28 días, desviación de 7 días,

proporción de días en cero en las últimas 4 semanas, stock de cierre del día anterior y días de cobertura (stock / media de 7 días). Del calendario: día de la semana, mes, día del mes, fin de semana y feriado (feriados nacionales de Bolivia, Carnaval, Viernes Santo, Corpus Christi y el 15 de abril de Tarija). Además el código del insumo como variable categórica.

3. Modelo y línea base

Línea base. Naive estacional: el consumo de mañana es igual al del mismo día de la semana anterior (lag 7). No se entrena y se evalúa sobre las mismas filas de prueba que el modelo.

Modelo. LightGBM 4.7.0 entrenado desde cero (no hay partes preentrenadas). La salida se entrena sobre el consumo dividido por la media de entrenamiento del insumo y luego se vuelve a escalar. Parámetros: learning_rate 0,03, num_leaves 31, min_data_in_leaf 40, feature_fraction 0,8, bagging_fraction 0,8, lambda_l2 1, semilla 42, parada temprana de 100 rondas sobre validación. Se probaron tres funciones de pérdida y se eligió la de menor MASE en validación: L2 0,947, L1 0,934, Tweedie 0,934 (679 árboles). Tweedie tiene sentido aquí porque el consumo es no negativo y tiene muchos ceros en los insumos de producción.

Artefactos. model/artifacts/model.txt (modelo LightGBM) y metadata.json (códigos de insumo, escalas, desviación de residuos de validación y parámetros). El backend carga ambos al iniciar.

4. Métricas y validación

Métrica principal: MASE. Error absoluto medio del modelo dividido por el error absoluto medio del naive estacional (lag 7) calculado en el periodo de entrenamiento de cada insumo. Es comparable entre insumos con unidades distintas (ml, g, unidades), no se indefine con días en cero como el MAPE, y menor a 1 indica que el modelo supera a la línea base. Se reporta el promedio de los 14 insumos.

Métricas complementarias. WAPE (error absoluto total sobre consumo total) diario y semanal, porque la compra se decide por semana; y sesgo (error con signo sobre consumo total), porque subestimar lleva a faltantes y sobreestimar a vencimientos.

Validación. División por fecha, sin mezclar: entrenamiento 29/10/2021–30/06/2025 (18 774 filas), validación 01/07/2025–31/12/2025 (2 576) y prueba 01/01/2026–03/10/2026 (3 864). Los primeros 28 días se descartan porque no tienen rezagos completos. La validación se usó para elegir la pérdida y el número de árboles. La prueba se usó una sola vez al final. Las escalas de normalización y el denominador de la MASE salen solo de entrenamiento. Todas las variables están desplazadas al menos un día, así que el consumo y el stock del propio día nunca entran como predictores.

5. Resultados

Conjunto de prueba (promedio de 14 insumos)	LightGBM	Línea base (lag 7)
MASE (principal)	0,934	1,323
MASE mediana	0,796	1,153
WAPE diario	44,5 %	63,6 %
WAPE semanal	18,9 %	20,9 %
Sesgo	-9,6 %	-1,0 %
Insumos donde gana	14 de 14	–

Tabla 1. Resultados en prueba (01/01/2026 – 03/10/2026).

Insumo	Unidad	MASE modelo	MASE base	WAPE modelo	WAPE base	Sesgo modelo
Chocolate en polvo	g	0,751	1,037	33,2 %	45,8 %	-3,5 %
Huevo	und	0,757	1,100	82,7 %	120,2 %	-28,1 %

Leche entera	ml	0,760	1,101	20,1 %	29,2 %	-4,1 %
Harina	g	0,769	1,157	84,0 %	126,3 %	-31,3 %
Cafe en grano	g	0,778	1,111	17,8 %	25,5 %	-5,7 %
Naranja	und	0,782	1,111	45,9 %	65,3 %	-1,7 %
Azucar blanca	g	0,795	1,158	32,1 %	46,7 %	-6,8 %
Mantequilla	g	0,796	1,150	58,8 %	84,9 %	-17,1 %
Jamon	g	0,825	1,201	33,5 %	48,7 %	-6,2 %
Te en hojas	g	0,856	1,145	55,1 %	73,7 %	-5,1 %
Pan de molde	g	0,875	1,252	33,2 %	47,5 %	-5,9 %
Queso	g	0,936	1,333	33,4 %	47,5 %	-5,5 %
Crema de leche	ml	1,653	2,223	47,6 %	64,0 %	-6,9 %
Tomate	g	1,744	2,448	46,1 %	64,7 %	-6,6 %

Tabla 2. Resultados por insumo en prueba.

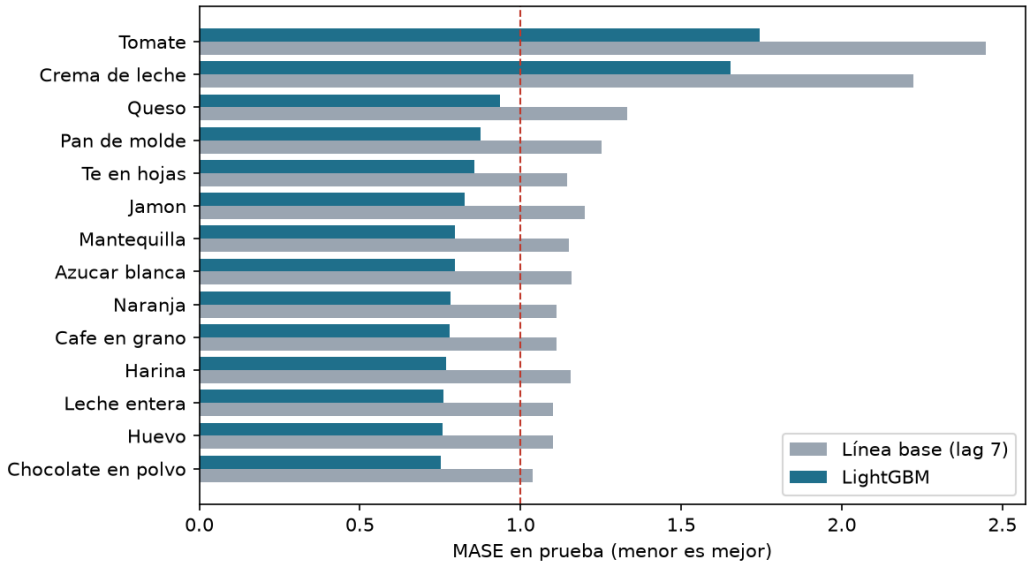


Figura 1. MASE por insumo. La línea roja marca MASE = 1.

Análisis de errores.

• El modelo reduce el error de la línea base en todos los insumos, entre 25 % y 34 %. La mejora viene sobre todo de no copiar picos aislados: la línea base repite cualquier día atípico de la semana anterior y el modelo lo suaviza con las medias móviles (Figura 2).

• Crema de leche y tomate tienen MASE mayor a 1 en ambos métodos. No es que el modelo sea peor ahí: esos insumos recién se usan desde 2024 (sándwich napolitano), así que el periodo de entrenamiento tiene más de dos años en cero y el denominador de la MASE queda muy chico. Su WAPE (46 %) es parecido al del resto.

• Harina y huevo son el caso difícil: se consumen por lotes de producción y la mitad de los días son cero. El WAPE diario es alto (84 %) y el sesgo es negativo (–31 % y –28 %), es decir, el modelo reparte el consumo entre varios días en vez de acertar el día de producción. Para reponer, lo que importa es el total de la semana, y ahí el error baja mucho.

• El modelo subestima en promedio 9,6 % (la línea base casi no tiene sesgo). Por eso la reposición suma un stock de seguridad con el error de validación de cada insumo.

• Por día de la semana el error más alto está en sábado; en feriados el modelo mantiene el error y la línea base empeora (error escalado 0,50 contra 0,92), porque la base copia el día cerrado de la semana

anterior o no ve el cierre.

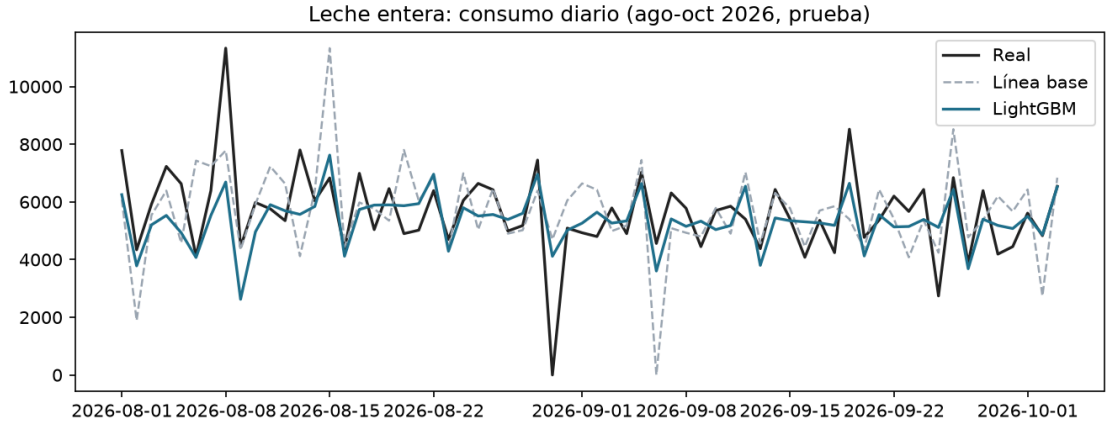


Figura 2. Leche entera, agosto a octubre de 2026 (prueba).

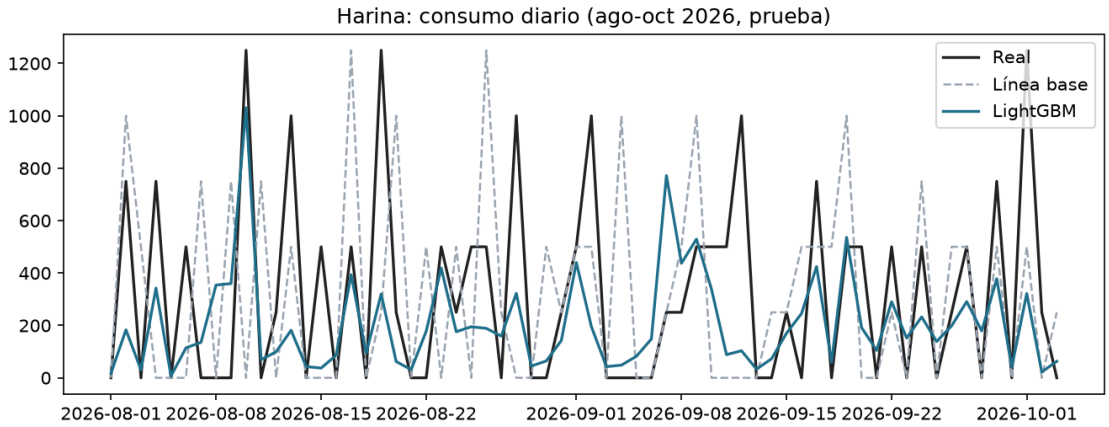


Figura 3. Harina: consumo por lotes, el caso difícil.

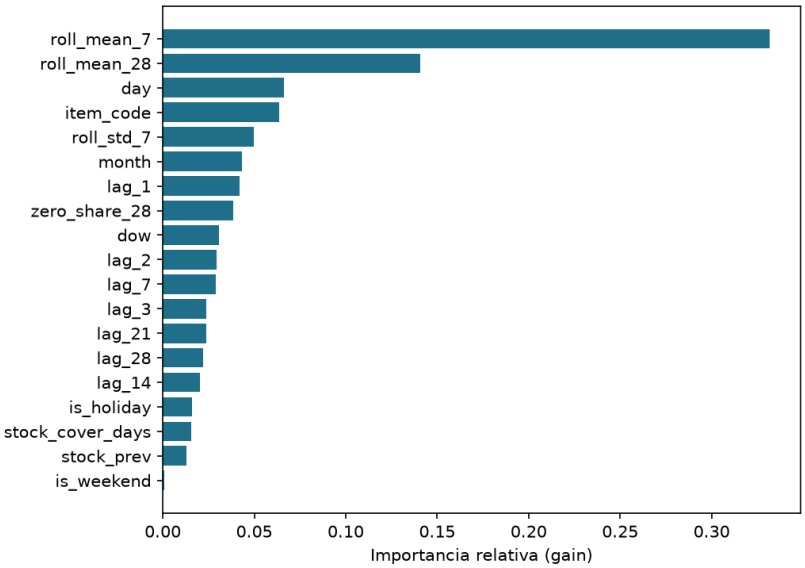


Figura 4. Importancia de variables (gain). Pesan más las medias móviles, los rezagos de 7 días y el día de la semana.

6. Arquitectura e interfaz

El sistema tiene tres partes. **Datos y modelo:** scripts de extracción, armado del dataset y entrenamiento en Python (pandas, LightGBM). **Backend:** API en FastAPI que valida la entrada con Pydantic, arma las variables con el mismo código usado en el entrenamiento (model/features.py) y

ejecuta el modelo cargado de model.txt. Para horizontes de más de un día predice de forma recursiva: la predicción de mañana entra como rezago para pasado mañana y el stock se descuenta con el consumo predicho. Luego calcula días de cobertura, stock de seguridad (z = 1,65 por la desviación de residuos de validación por la raíz de los días de entrega) y cantidad sugerida. **Frontend:** página HTML con JavaScript que el mismo backend sirve; permite cargar el historial desde el kardex o subir un CSV, muestra estado de carga, errores y los límites de la solución.

Endpoint	Descripción
GET /api/salud	Estado y versión del modelo
GET /api/insumos	Lista de insumos con unidad y MASE de prueba
GET /api/historial	Historial de un insumo hasta una fecha (para la demostración)
POST /api/predecir	Recibe insumo, historial ≥ 28 días, stock, horizonte y días de entrega

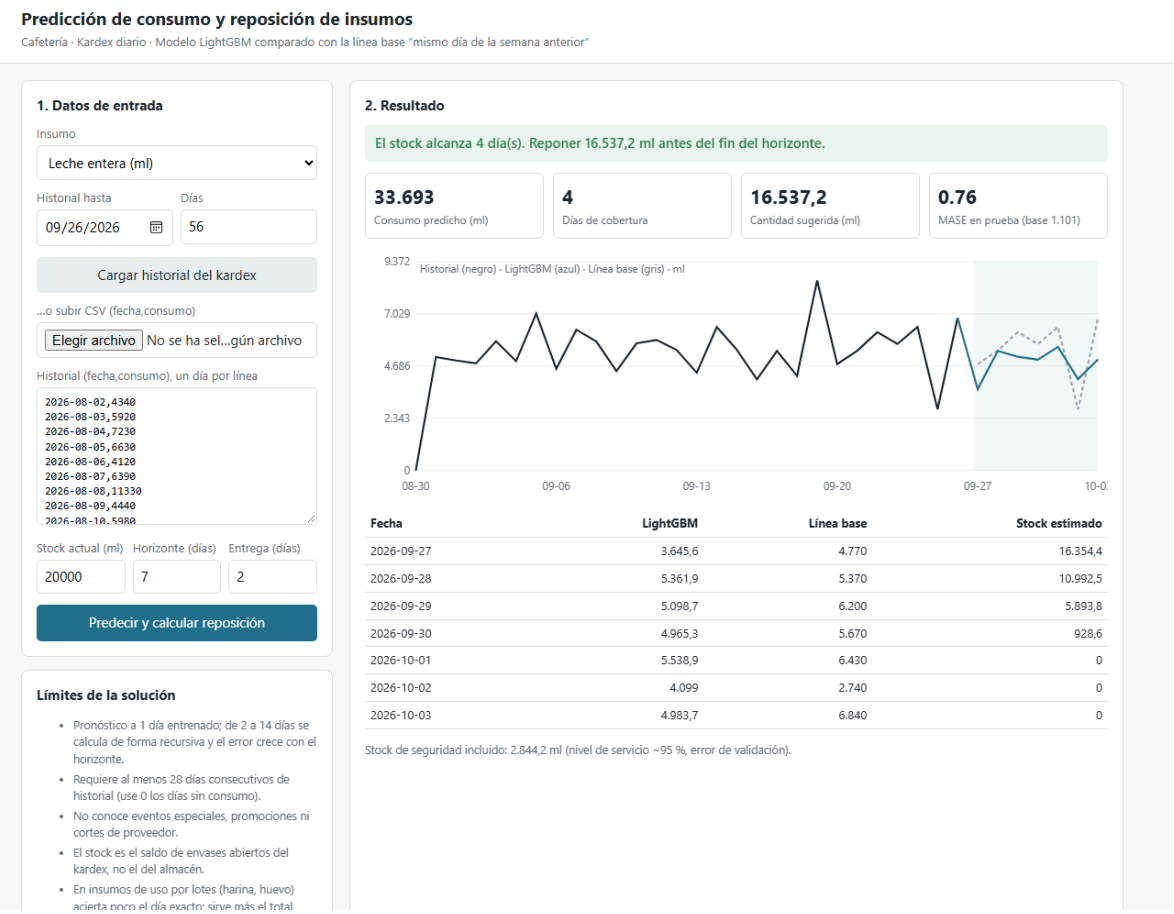


Figura 5. Caso válido: leche entera, stock 20 000 ml, 7 días, entrega en 2 días.

7. Pruebas realizadas

Las pruebas automáticas están en tests/test_api.py (pytest, 10 pruebas, todas pasan). Cubren:

• **Caso válido**: leche entera con 56 días de historial; responde 7 días con valores no negativos y en el rango real del insumo.

• **El resultado sale del modelo**: dos historiales distintos dan pronósticos distintos (no hay respuestas fijas).

• **Caso difícil**: harina con consumo intermitente y stock en cero a 14 días; el sistema avisa que hay que pedir hoy y sugiere una cantidad positiva.

• **Entradas inválidas**: insumo desconocido, menos de 28 días, consumo negativo, horizonte mayor a 14 y días faltantes en el historial. Todas devuelven 422 con un mensaje en español.

• **Flujo completo**: página principal → lista de insumos → historial → predicción, por el mismo camino que usa la interfaz.

Las pruebas se corrieron en un entorno virtual con las versiones fijadas en requirements.txt, siguiendo los pasos del README.

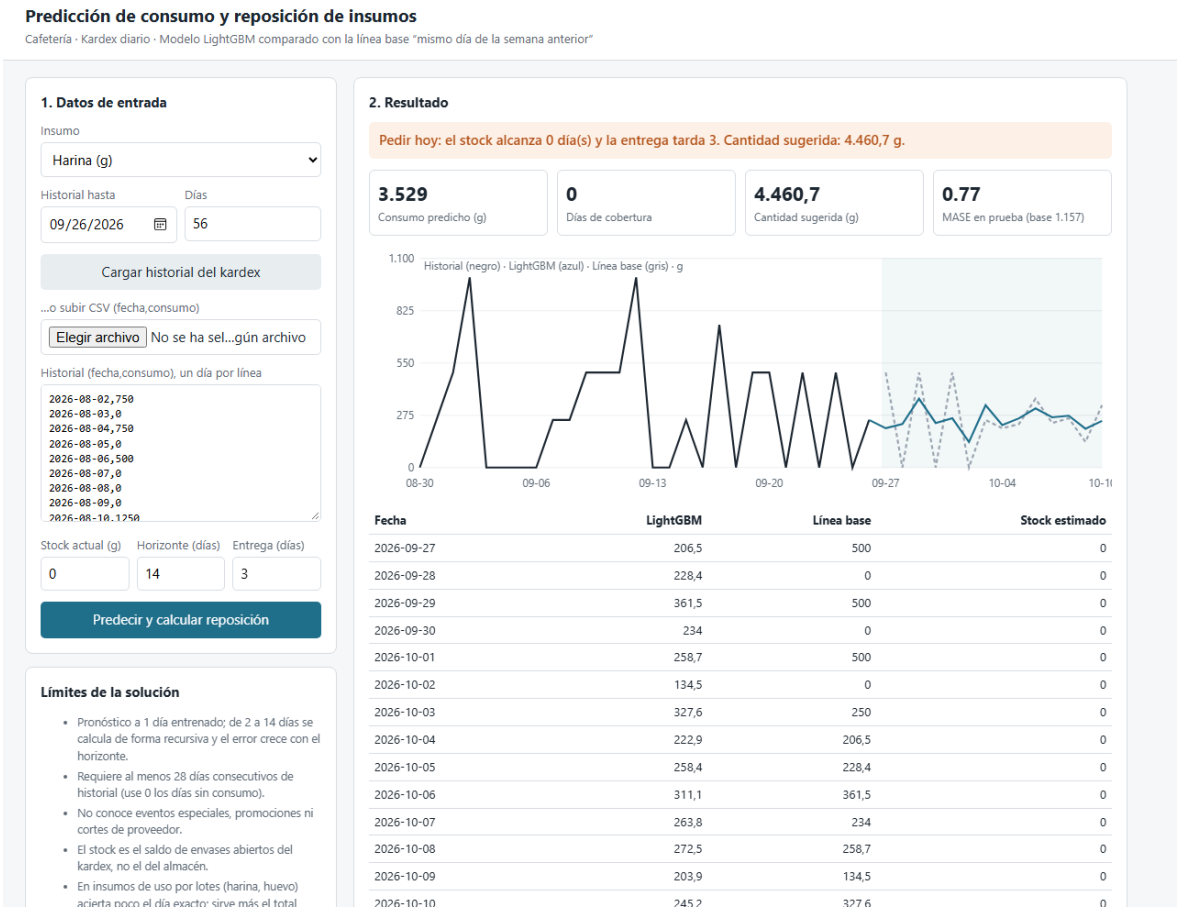


Figura 6. Caso difícil: harina, stock 0, horizonte 14 días.

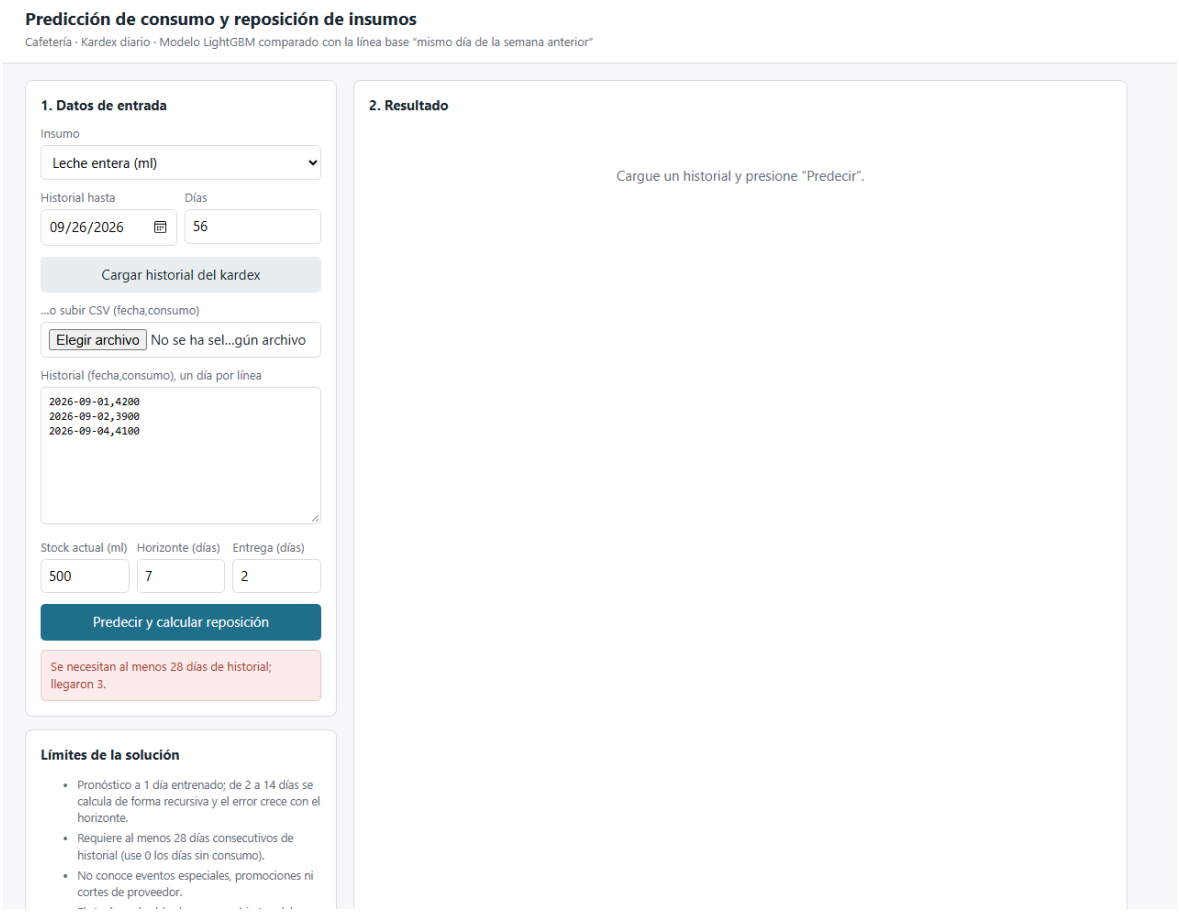


Figura 7. Entrada inválida: historial de solo 3 días. El backend rechaza la petición y explica el motivo.

8. Conclusiones

El modelo LightGBM supera a la línea base en los 14 insumos, con MASE promedio de 0,934 frente a 1,323 y mediana de 0,796. La comparación se hizo sobre nueve meses de 2026 que el modelo no vio, con división temporal y sin fugas. El sistema funciona de punta a punta: se carga el historial, el backend ejecuta el modelo real y la interfaz muestra cuánto se va a consumir, cuántos días alcanza el stock y cuánto pedir.

La mejora es clara en el día a día, pero en el total semanal la diferencia es menor (18,9 % contra 20,9 % de WAPE). Para la decisión de compra, que se hace por semana, la ganancia práctica está más en evitar sobrerreacciones a días atípicos que en un acierto diario fino.

9. Limitaciones

• Se entrenó a un día. Para 2 a 14 días el pronóstico es recursivo y el error crece; no se evaluó por separado el error a 7 días.

• El stock disponible es el saldo de envases abiertos según el kardex, no el inventario de almacén; por eso en la interfaz el stock lo ingresa el usuario.

• No hay datos de promociones, eventos, clima ni cortes de proveedor.

• Subestima en promedio; en insumos de producción por lotes el sesgo llega a –31 %.

• Es una sola cafetería; no se probó en otros negocios.

10. Referencias

Hyndman, R. J., & Koehler, A. B. (2006). Another look at measures of forecast accuracy. *International Journal of Forecasting, 22*(4), 679–688.

Hyndman, R. J., & Athanasopoulos, G. (2021). *Forecasting: Principles and Practice* (3.ª ed.). OTexts. https://otexts.com/fpp3/

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems, 30*.

Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2022). M5 accuracy competition: Results, findings, and conclusions. *International Journal of Forecasting, 38*(4), 1346–1364.

Silver, E. A., Pyke, D. F., & Thomas, D. J. (2017). *Inventory and Production Management in Supply Chains* (4.ª ed.). CRC Press.